深度学习-Vision Transformer (ViT)

黄海广 副教授

2022年05月

本章目录

01 背景知识

02 模型介绍

03 模型训练策略

04 模型的缺点与改进

05 模型的代码实现

1.背景知识

01 背景知识
02 模型介绍
03 模型训练策略
04 模型的缺点与改进
05 模型的代码实现

1.背景知识

图片分类的原理

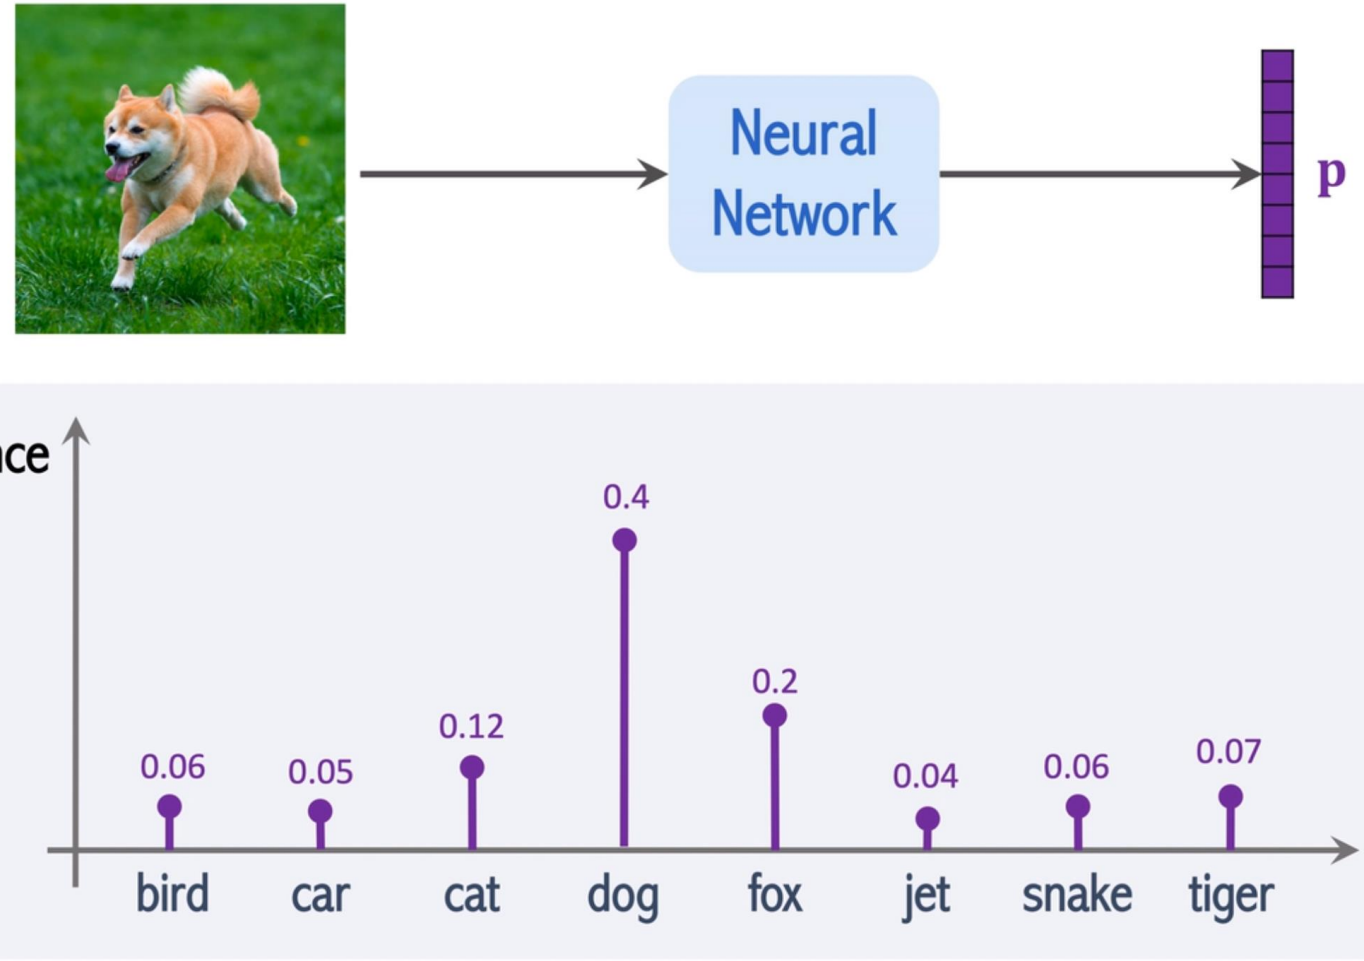

1.背景知识

2017年google的机器翻译团队在NIPS上发表了**Attention is all you need**的文章，开创性地提出了在序列转录领域，完全抛弃CNN和RNN，只依赖Attention-注意力结构的简单的网络架构，名为Transformer；论文实现的任务是机器翻译。

Transformer结构

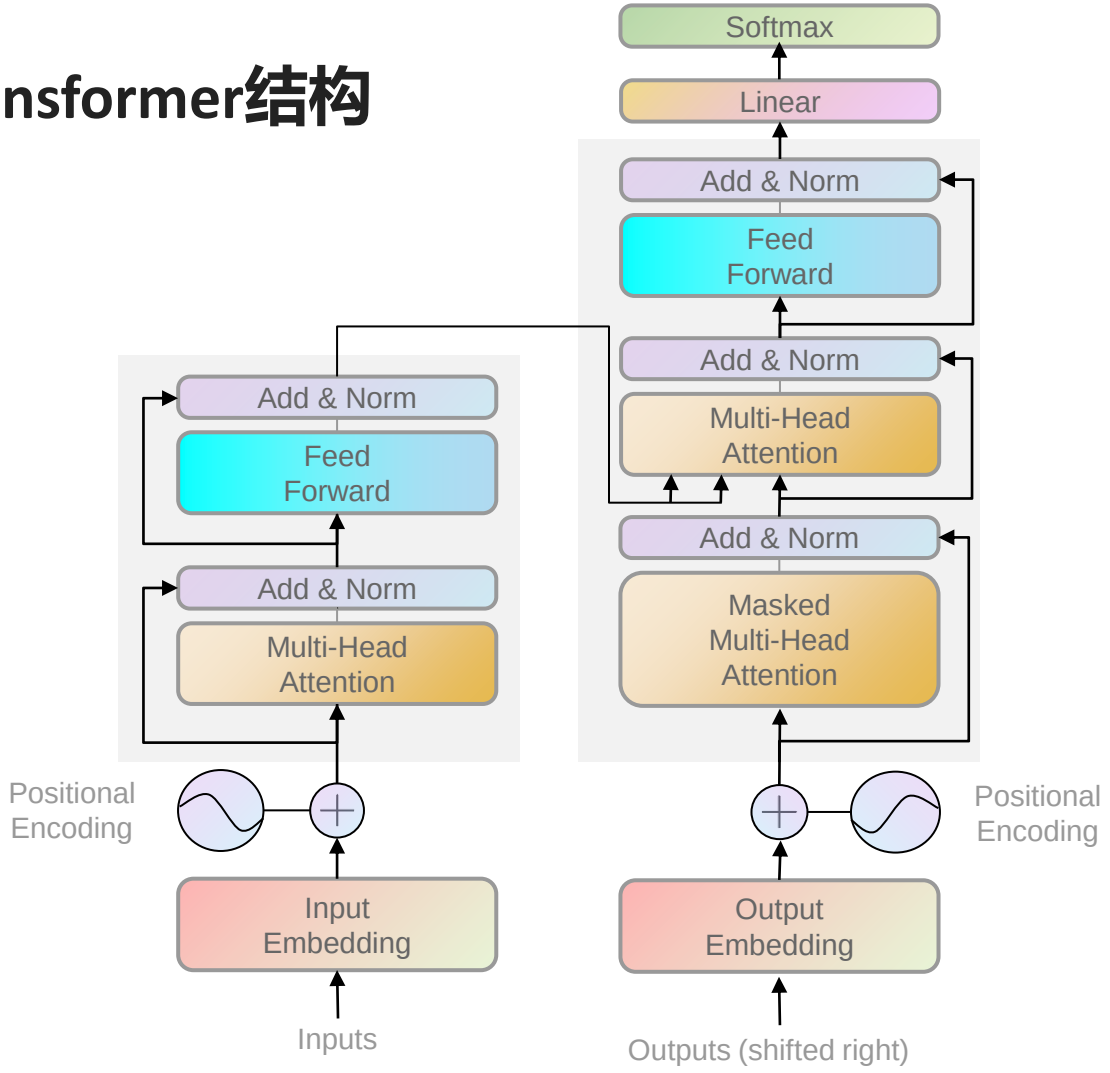

1.背景知识

为什么需要用transformer

Transformer原本是用来做NLP的工作的，所以ViT的首要任务是将图转换成词的结构，这里采取的方法是如上图左下角所示，将图片分割成小块，每个小块就相当于句子里的一个词。这里把每个小块称作Patch，而**Patch Embedding**就是把每个Patch再经过一个全连接网络压缩成一定维度的向量。

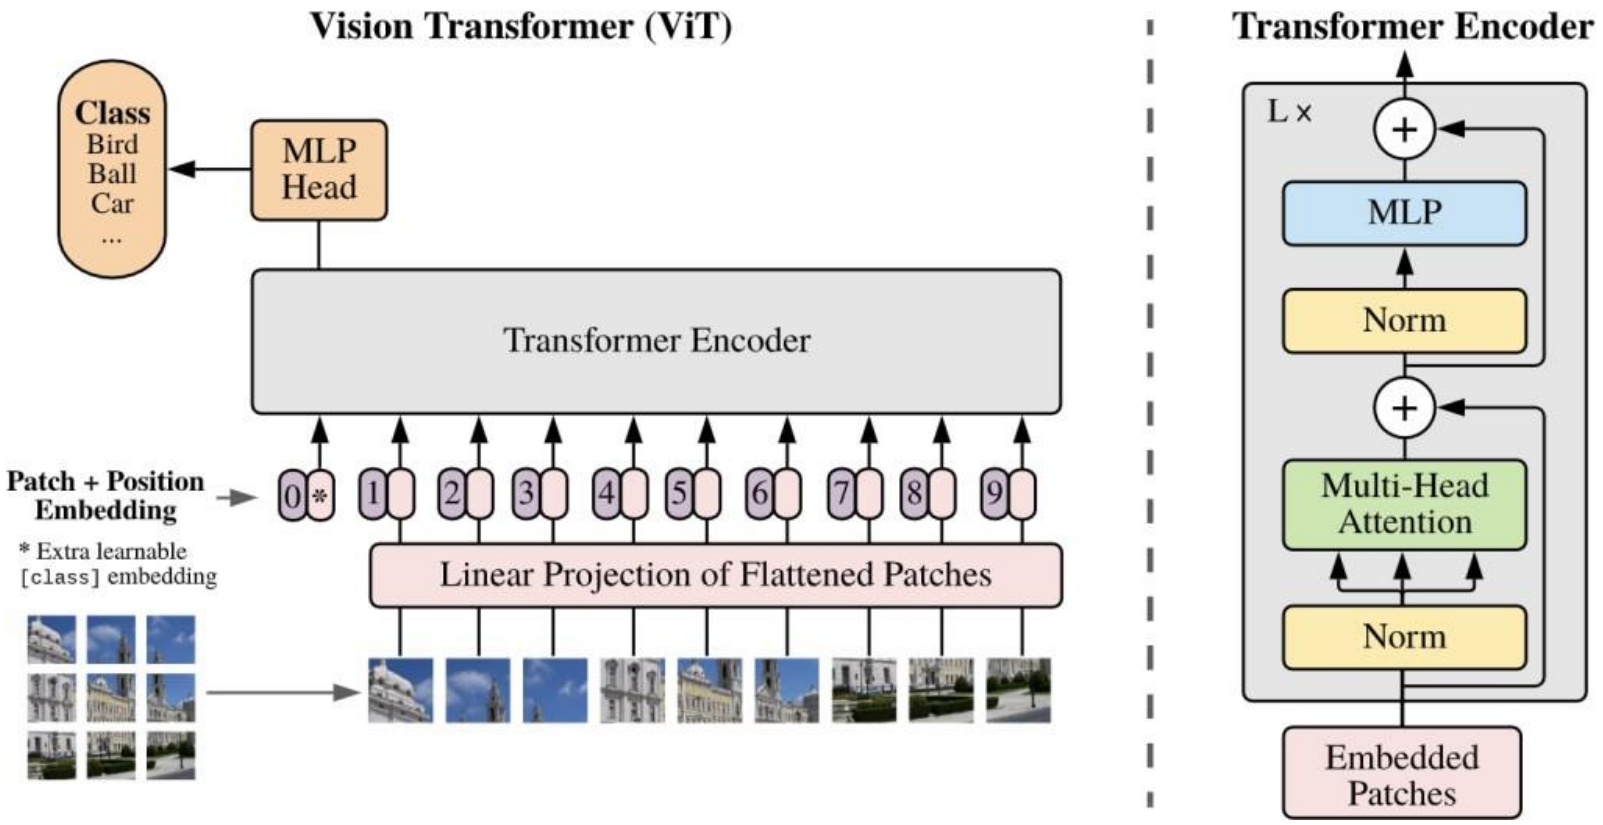

1.背景知识

为什么需要用transformer

CNN（如ResNet）是图像分类的最佳解决方案。

如果预训练的数据集足够大（至少一亿张图像），则Vision Transformer（ViT）将击败CNN（小幅度）

Vision Transformer（ViT）实际上就是Transformer的encode网络。

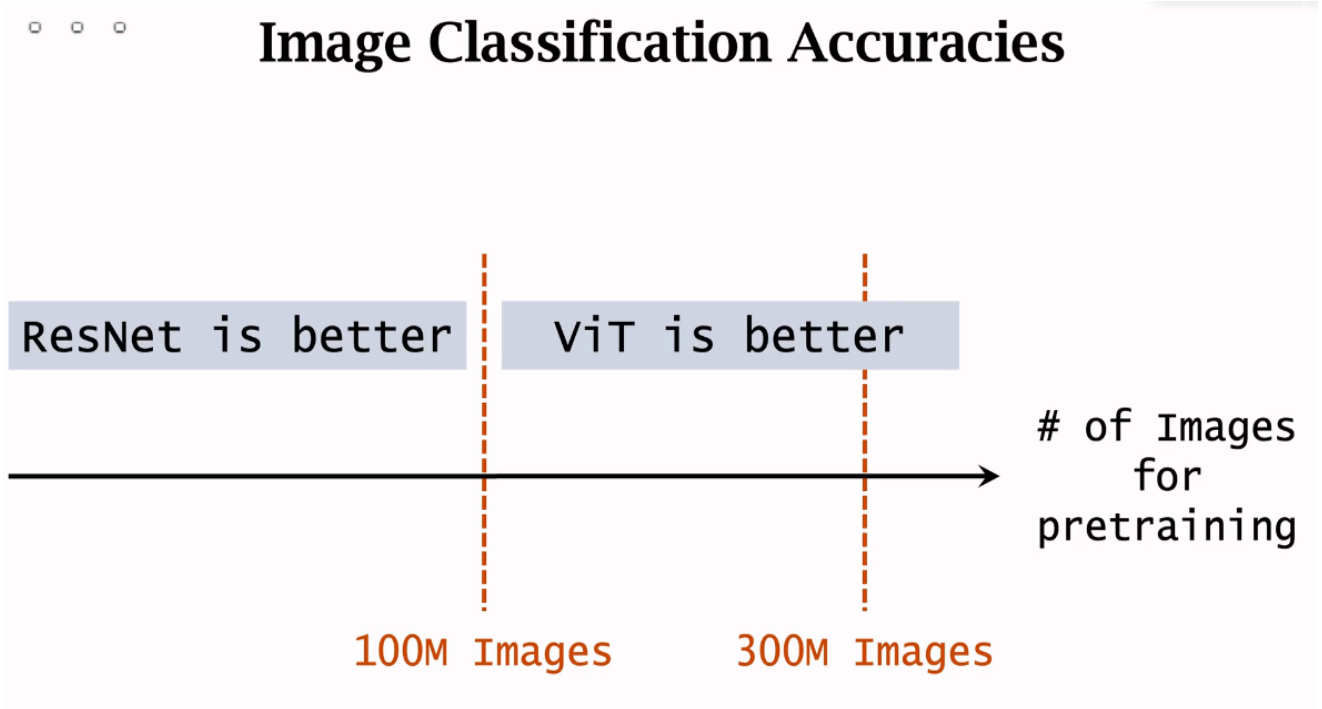

2.模型介绍

01 背景知识

02 模型介绍

03 模型训练策略

04 模型的缺点与改进

05 模型的代码实现

2.模型介绍

01 背景知识

02 模型介绍

03 模型训练策略

04 模型的缺点与改进

05 模型的代码实现

2.模型介绍

模型思路

1.图片切分为patch

2.patch转化为embedding

3.位置embedding和tokensembedding相加

4.输入到Transformer模型

5.CLS输出做多分类任务

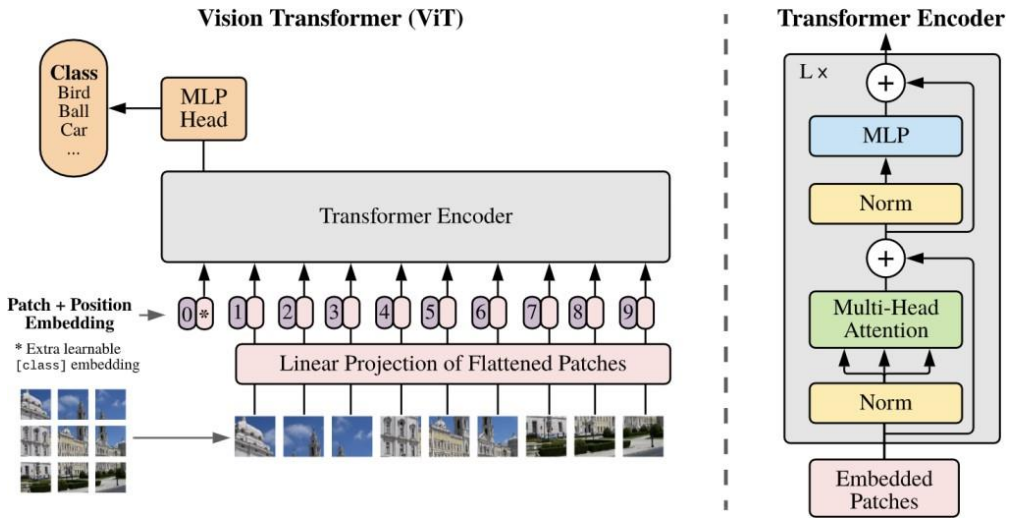

2.模型介绍

先将图片分成NxN的patch块(原始论文是16x16)
patch块可以重叠(上图没有重叠，是9x9的patch块)

2.模型介绍

将patch打平， 对每个 patch 进行线性映射，提取特征

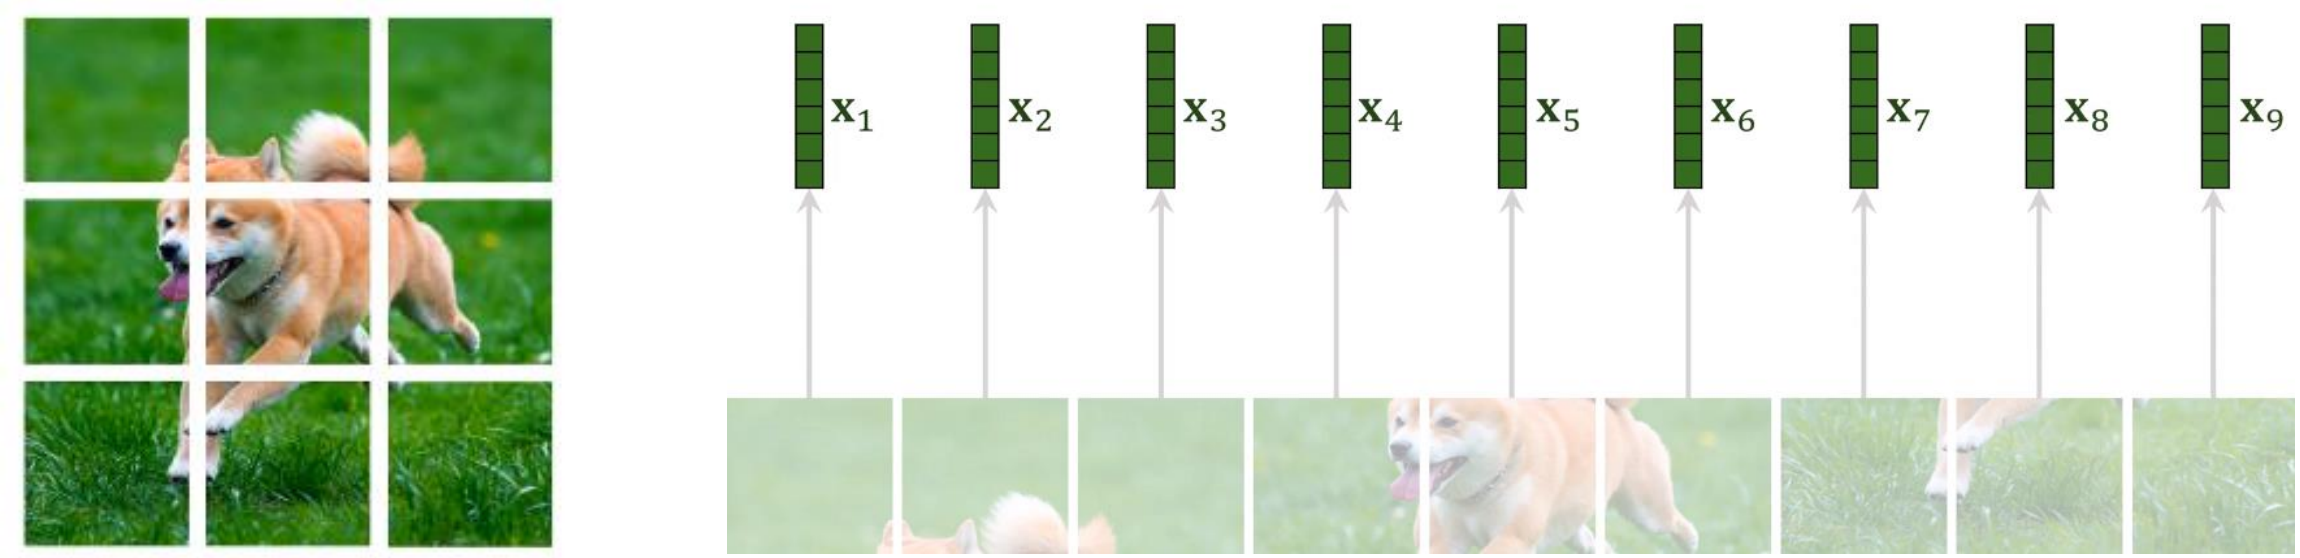

2.模型介绍

提取特征

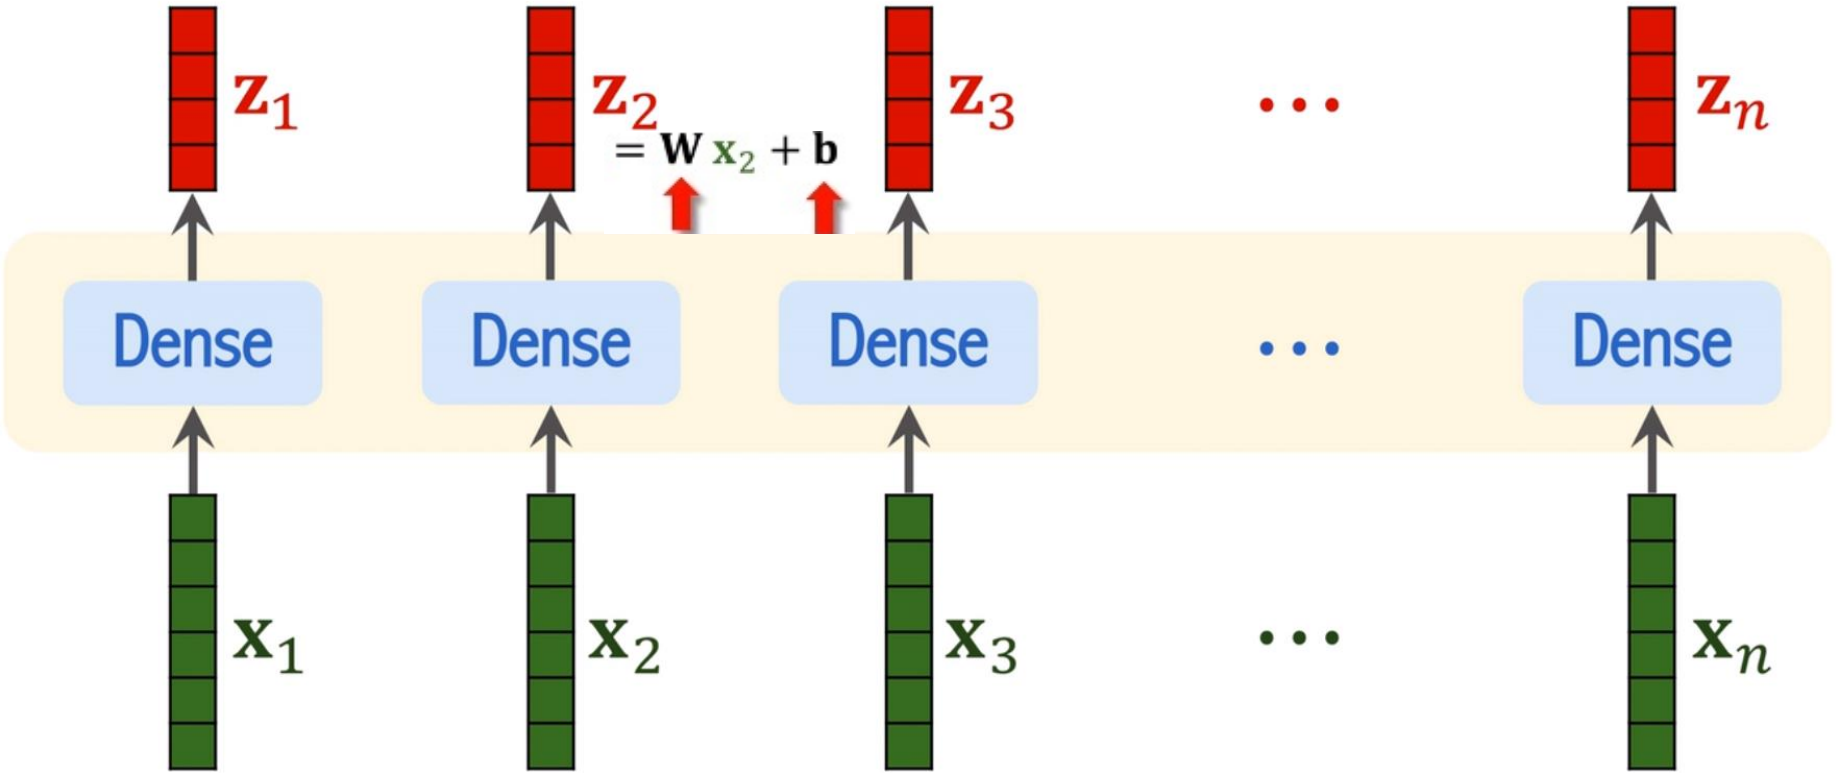

2.模型介绍

1.将位置编码信息加入提取的特征

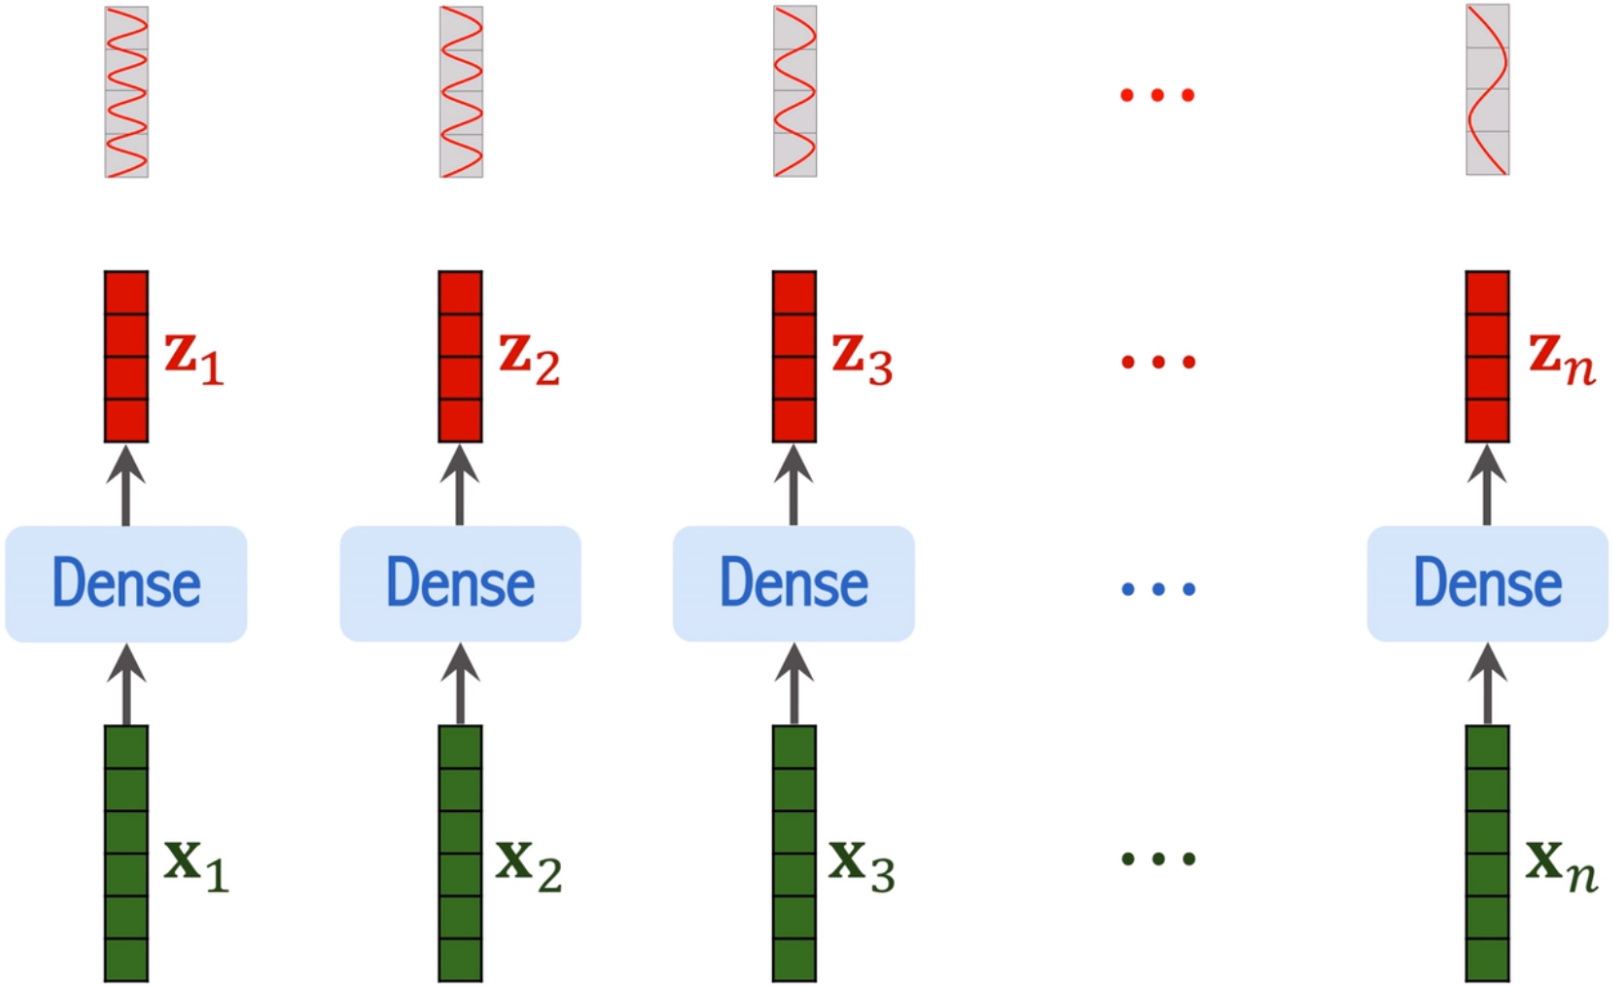

2.模型介绍

位置编码信息对准确率的影响

结论:编码有用,但是怎么编码影响不大,干脆用简单的得了

2D(分别计算行和列的编码,然后求和)的效果还不如1D的每一层都加共享的位置编码也没啥太大用

		最开始	每一层都加入 而且独立训练	每一层都加入 但是参数共享
	Pos. Emb.	Default/Stem	Every Layer	Every Layer-Shared
没有位置编码	No Pos. Emb.	0.61382	N/A	N/A
一维位置编码	1-D Pos. Emb.	0.64206	0.63964	0.64292
二维位置编码	2-D Pos. Emb.	0.64001	0.64046	0.64022
相对位置编码	Rel. Pos. Emb.	0.64032	N/A	N/A

2.模型介绍

位置编码

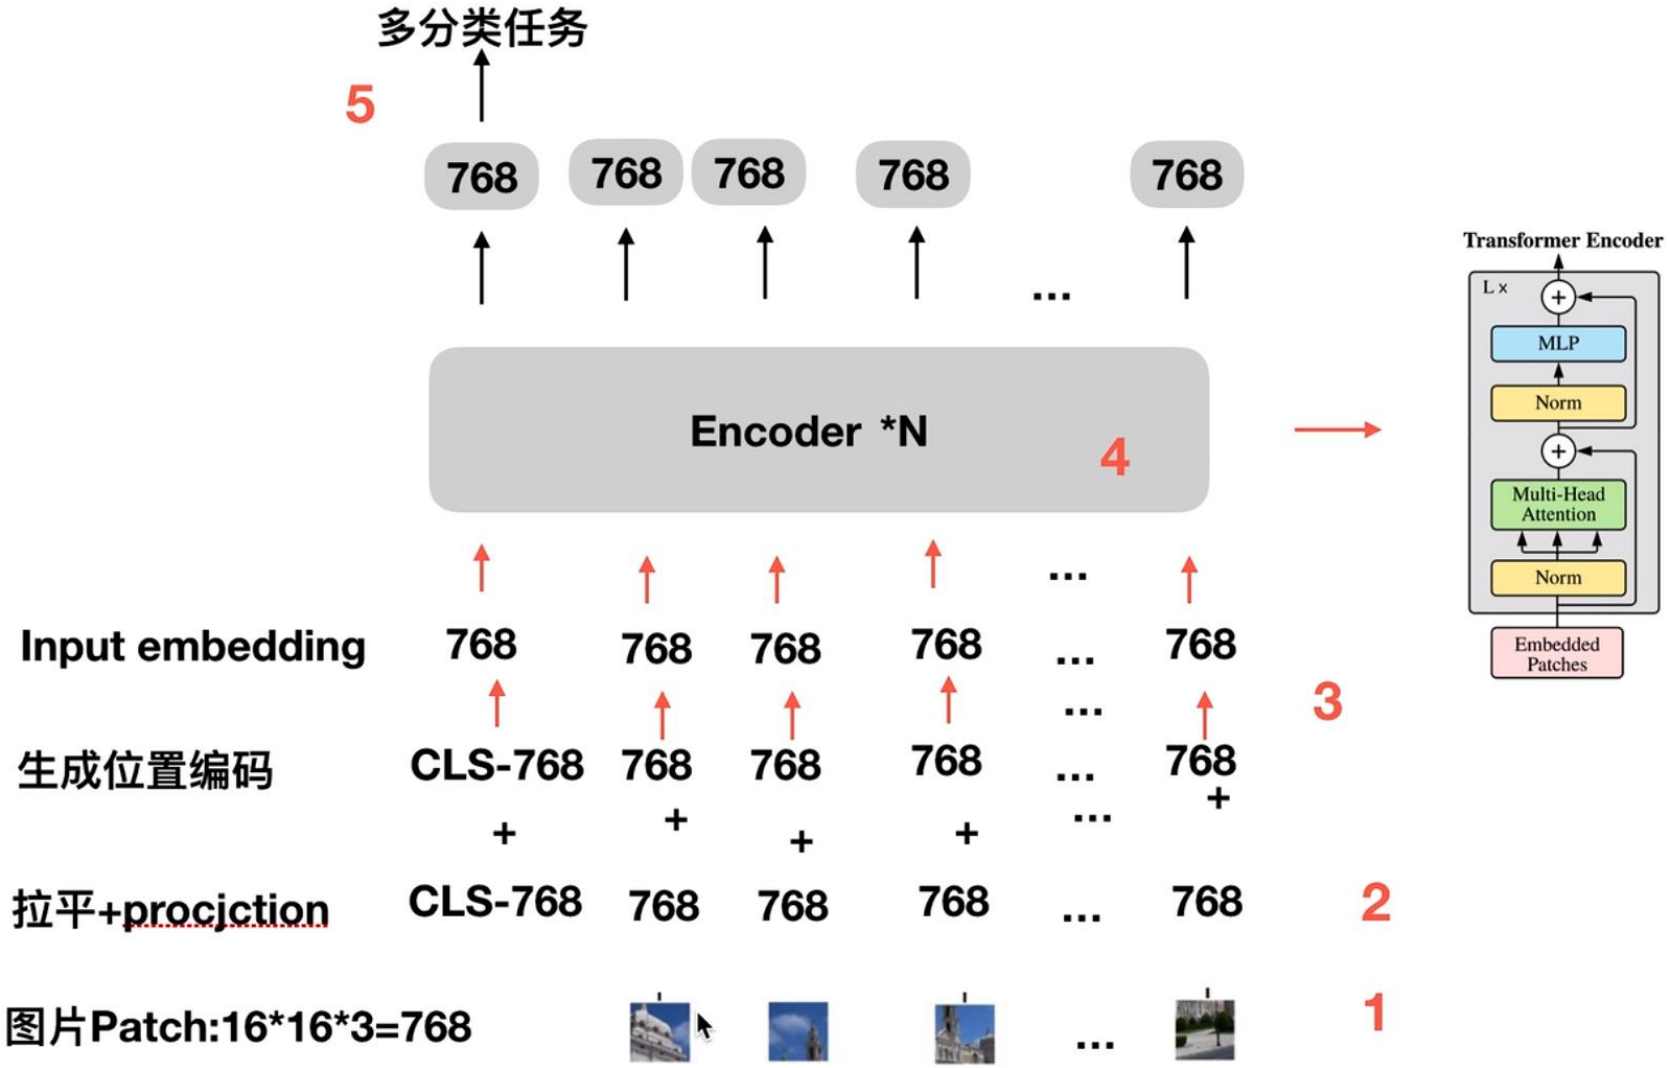
多分类任务
5
768
768
768
768
768
...
Encoder *N
4
Input embedding
768
768
768
768
...
768
生成位置编码
CLS-768
768
768
768
...
768
3
+
拉平+procjction
CLS-768
768
768
768
...
768
2
图片Patch:16*16*3=768
1
Transformer Encoder
L x
MLP
Norm
Multi-Head Attention
Norm
Embedded Patches

2.模型介绍

将3)的结果喂入标准Transformer的encoder中作者将类别作为一个可学习的patch（z_0)输入模型，与图像的patch+pos 信息作为multi-head attention 的输入。

可以叠加多层encoder：

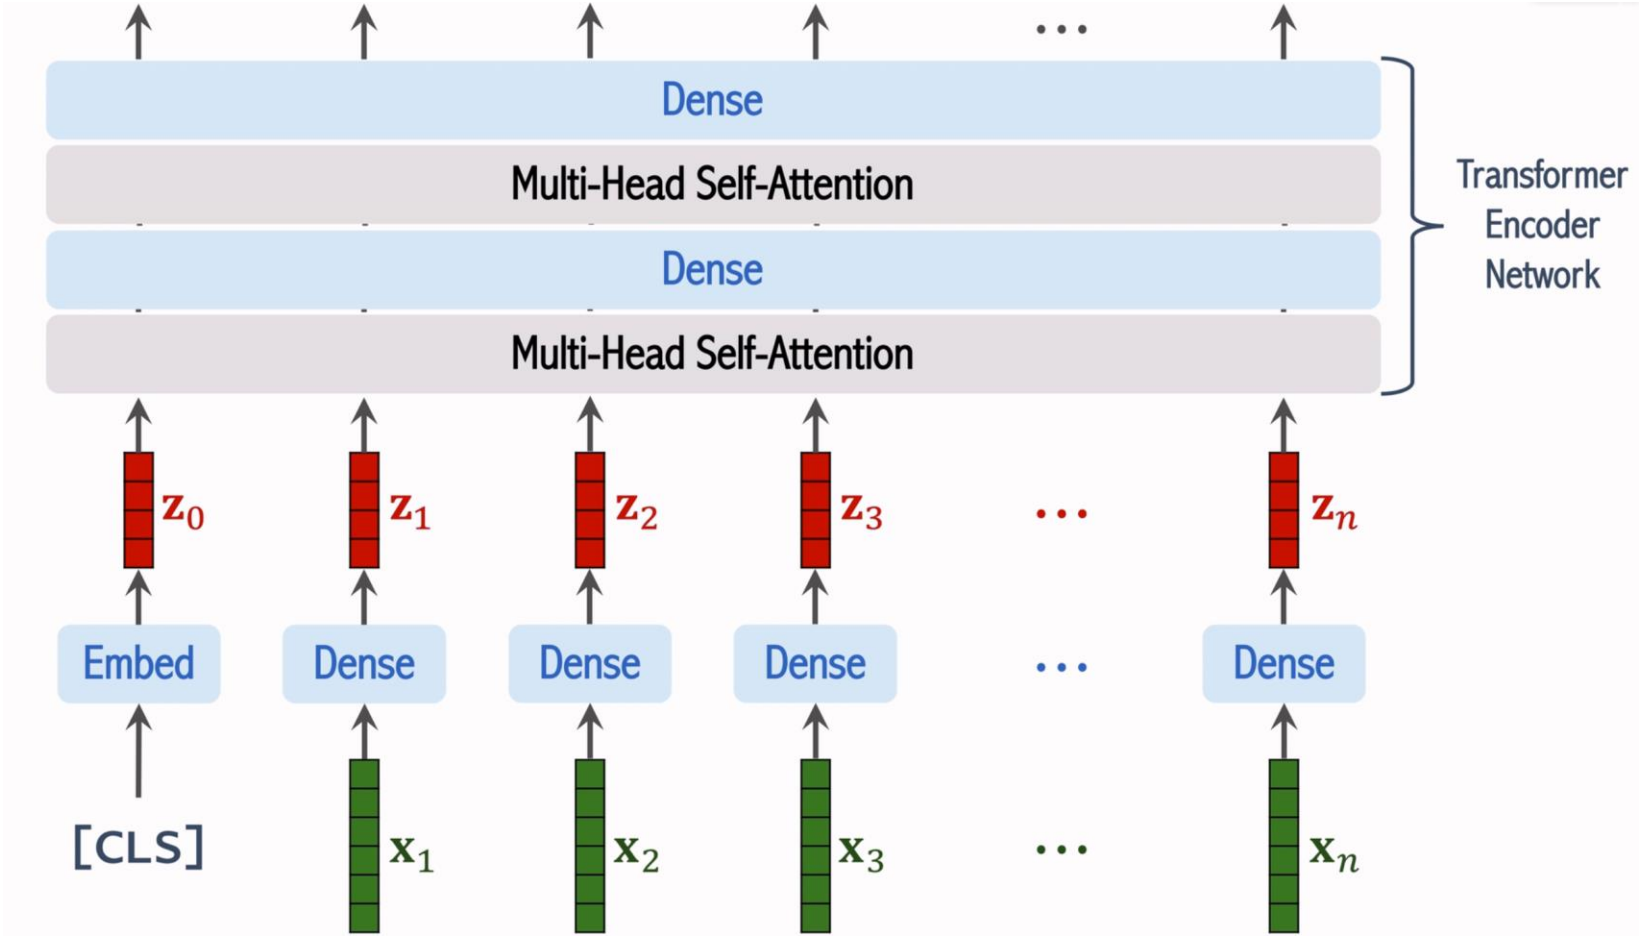

2.模型介绍

将encoder得到的结果输入分类层
encoder 会输出多个上下文向量，对于图像分类，只需要 C_0。

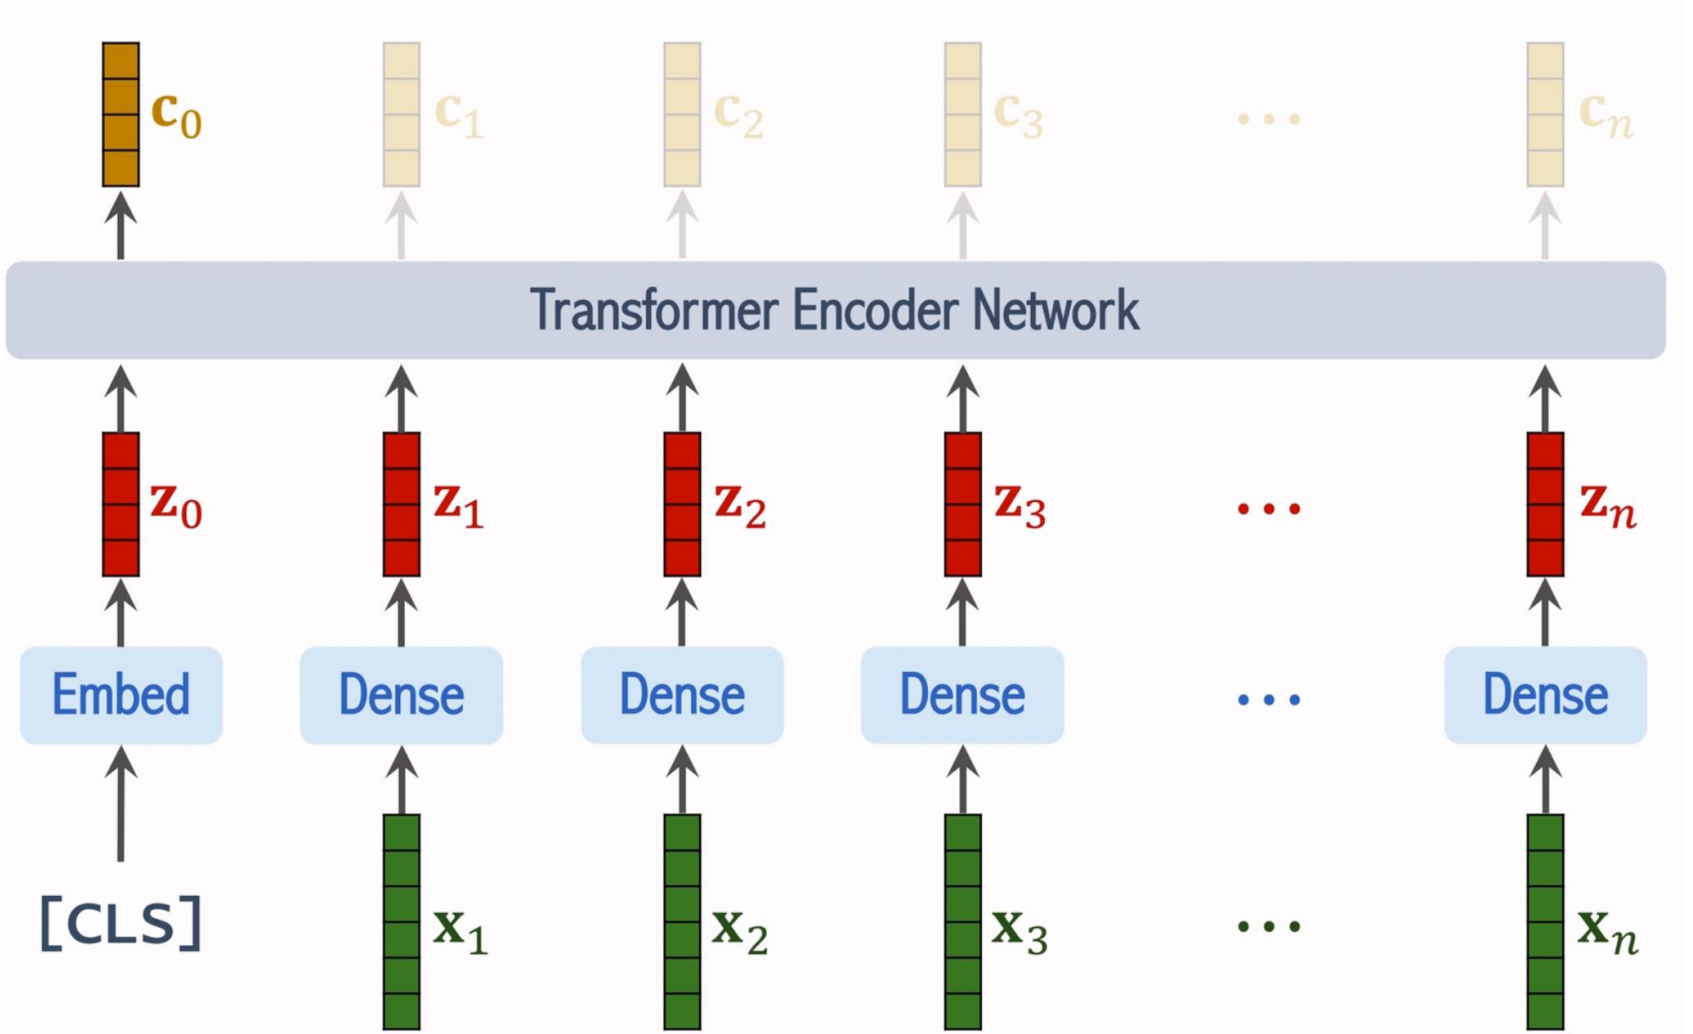

1.背景知识

将encoder得到的结果输入分类层
encoder 会输出多个上下文向量，对于图像分类，只需要 C_0。

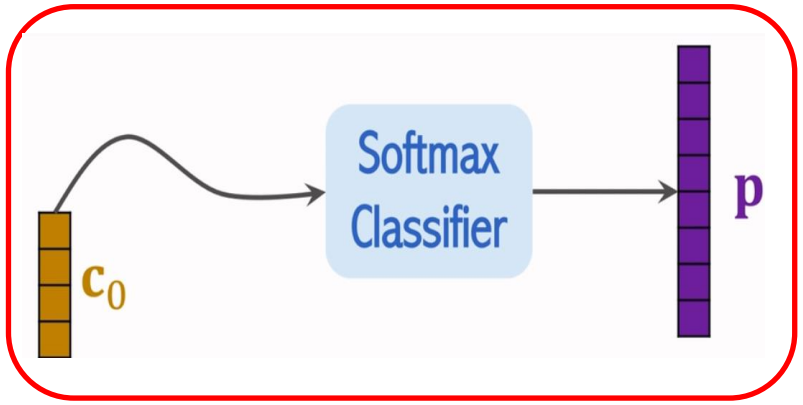

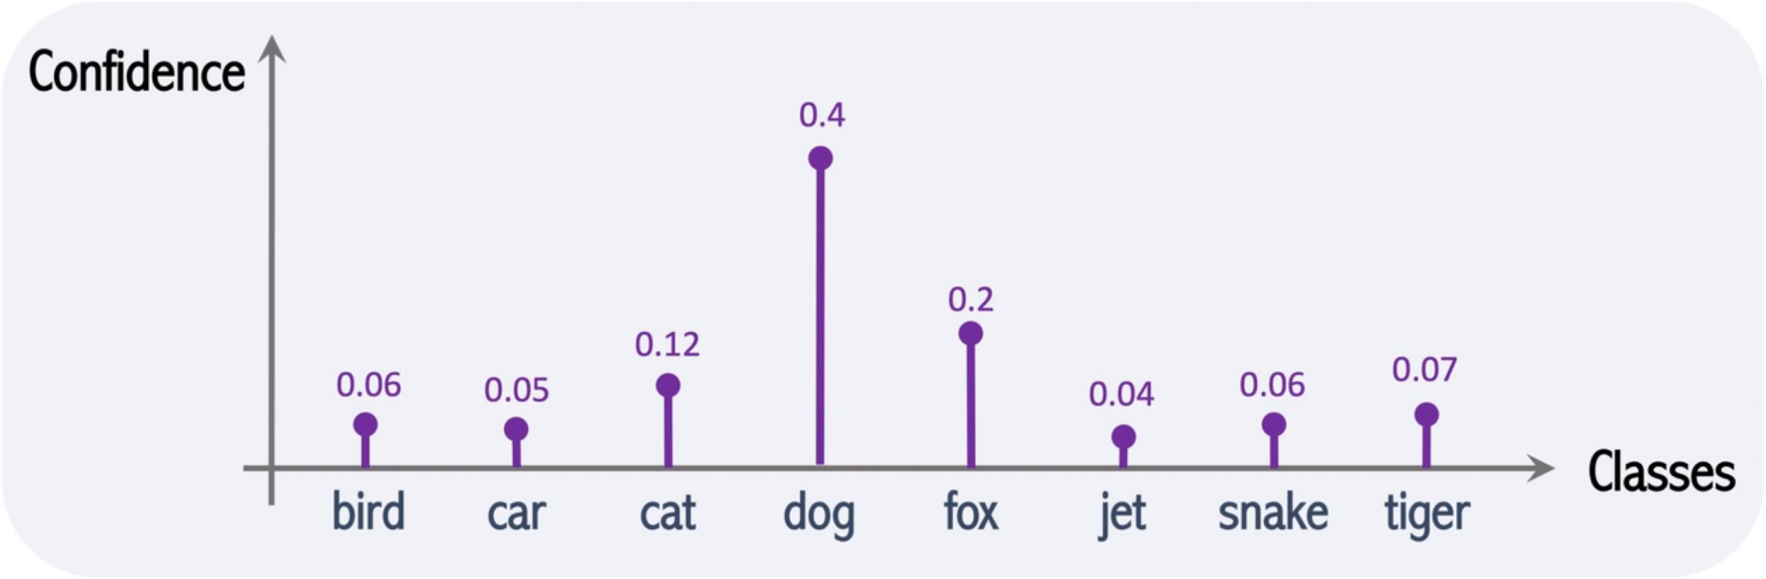

2.模型介绍

模型框架

最简洁的Vision Transformer模型，先将图片分成16x16的patch块，送入transformer encoder，第一个cls token的输出送入mlp head得到预测结果。

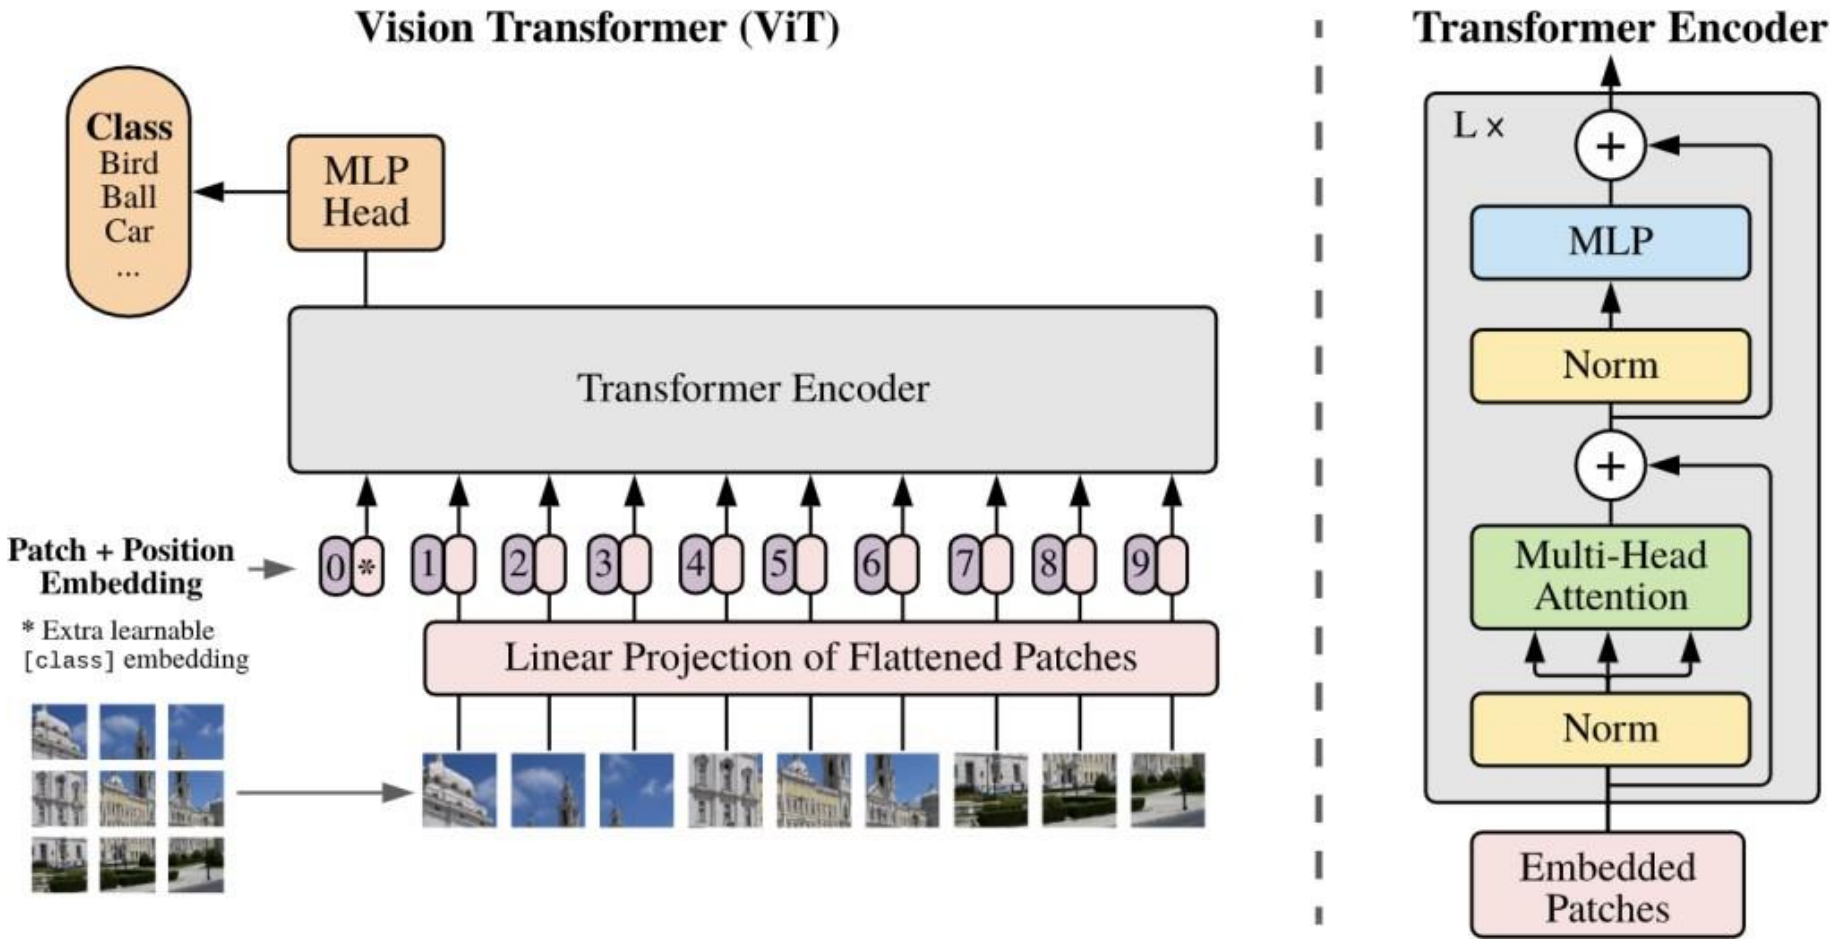

2.模型介绍

来自输入空间的注意力表达

输入 注意力 输入 注意力 输入 注意力

2.模型介绍

左图展示了模型学习到的图嵌入，中图展示了学习到的位置嵌入，右图展示了不同层注意力的平均距离。

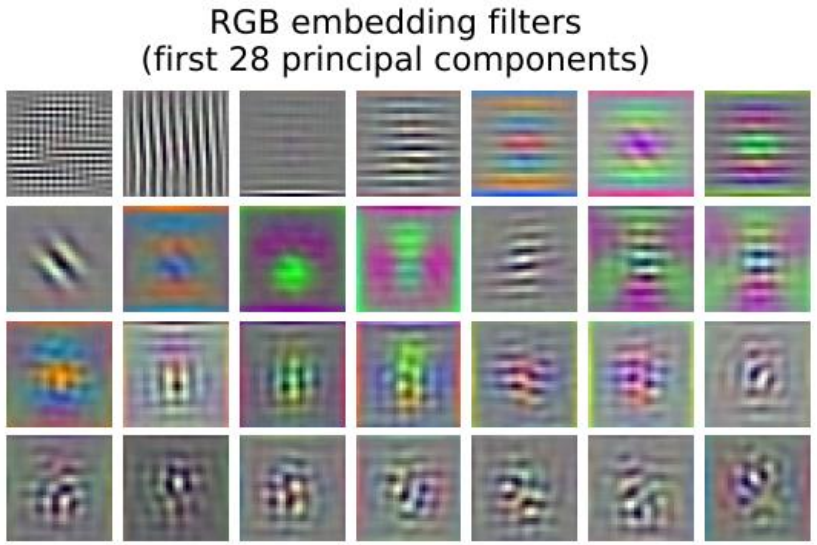

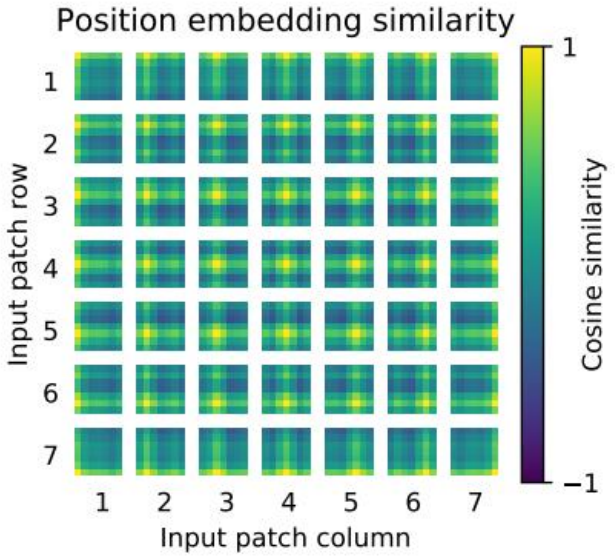

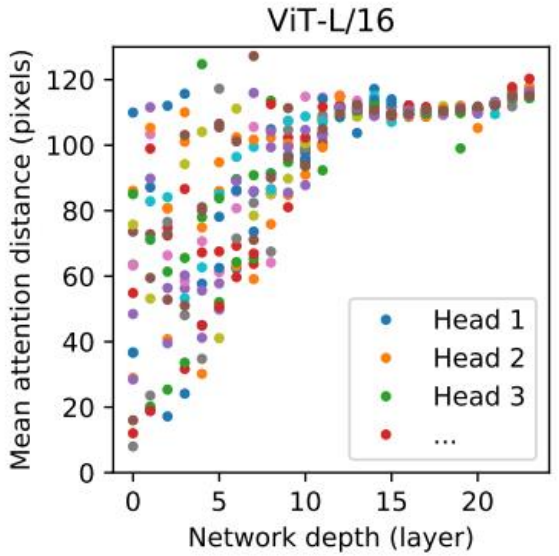

2.模型介绍

加入位置信息的原因

如下图所示，将左图的patch打乱，则两个图是不同的，但对于Transformer的最后一层来说会得到相同的特征(认为是一个图)，为了让其能够识别是两个图，加入位置信息(使两个图不一样)。

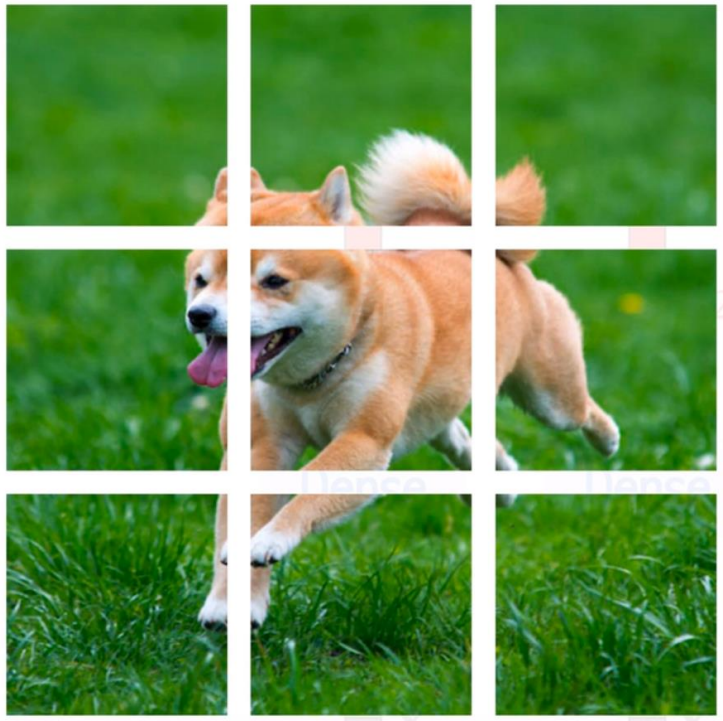

2.模型介绍

Patch 打平的具体做法

标准Transformer的输入是1D序列，对于图像$\mathbf{x} \in R^{H*W*C}$， 将其reshape成 $\mathbf{x}_p \in R^{N*\left(P^2 \cdot C\right)}$ 的序列。

P是patch的大小； (H,W)是图像的高和宽；C是图像通道数；$N = HW/P^2$，即patch的个数。

3.模型训练策略

01 背景知识

02 模型介绍

03 模型训练策略

04 模型的缺点与改进

05 模型的代码实现

3.模型训练策略

训练策略

模型在Dataset A上预训练，在Dataset B上精调，在Dataset B上评估

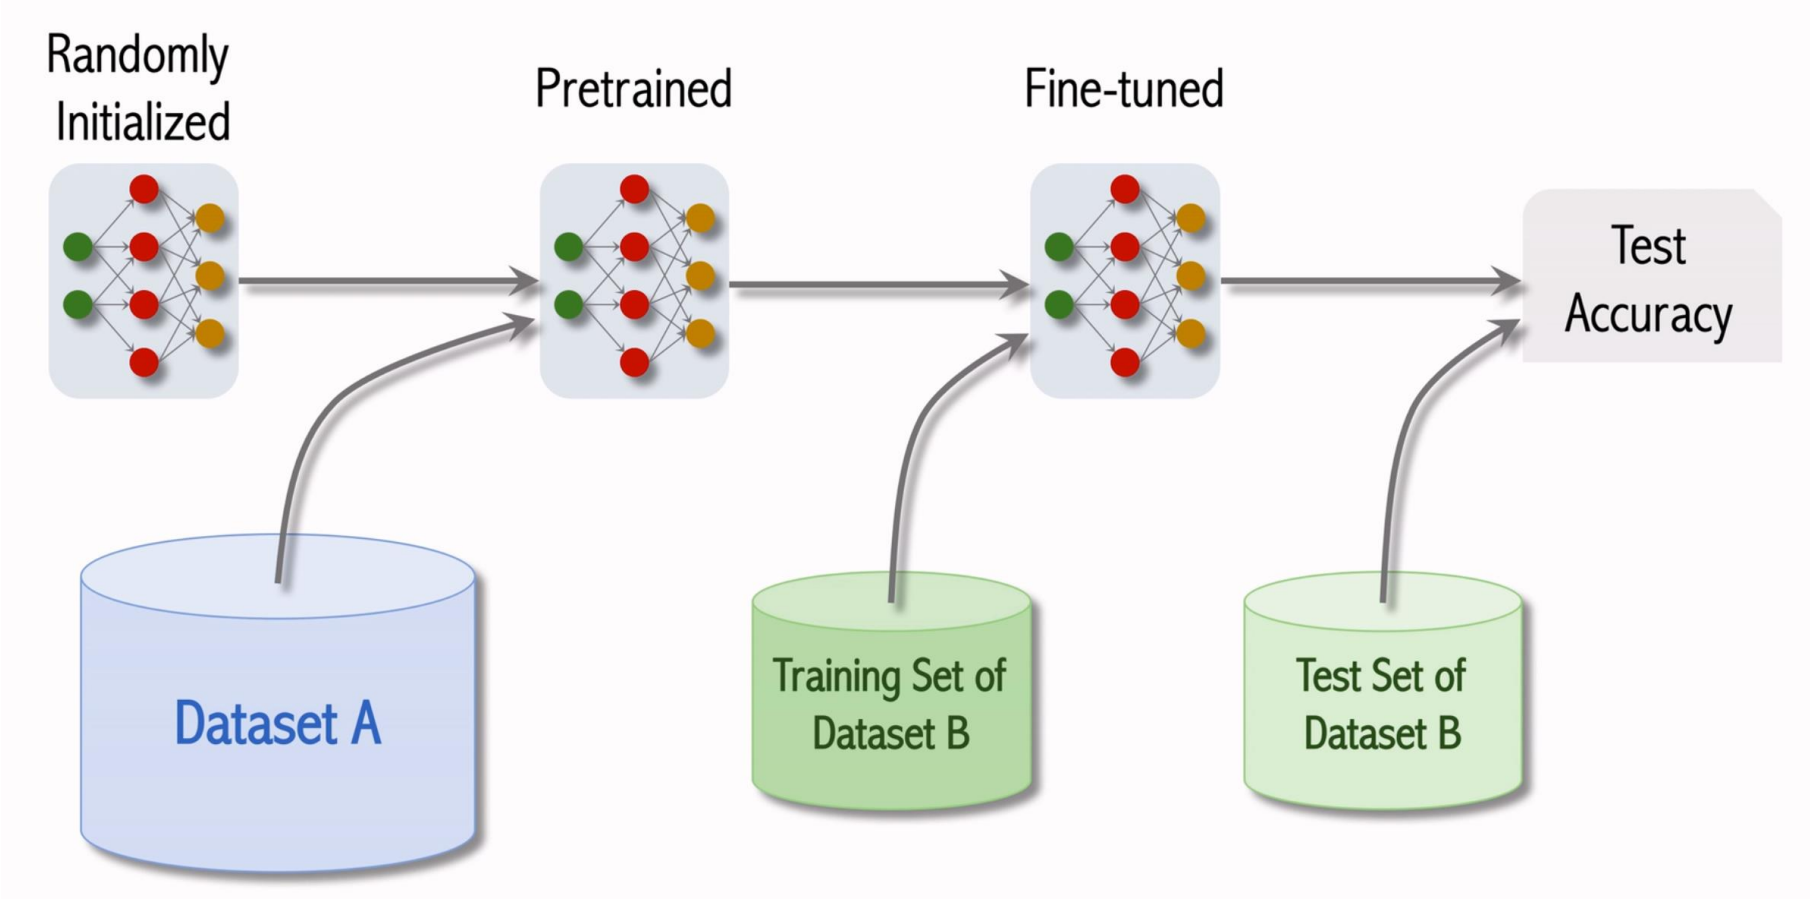

3.模型训练策略

数据集介绍

	# of Images	# of Classes
ImageNet (Small)	1.3 Million	1 Thousand
ImageNet-21K (Medium)	14 Million	21 Thousand
JFT (Big)	300 Million	18 Thousand

在ImageNet(small)预训练，ViT的效果低于Resnet。

在ImageNet-21K(medium)预训练，ViT的效果接近Resnet。

在JFT(large)预训练，ViT的效果优于Resnet。

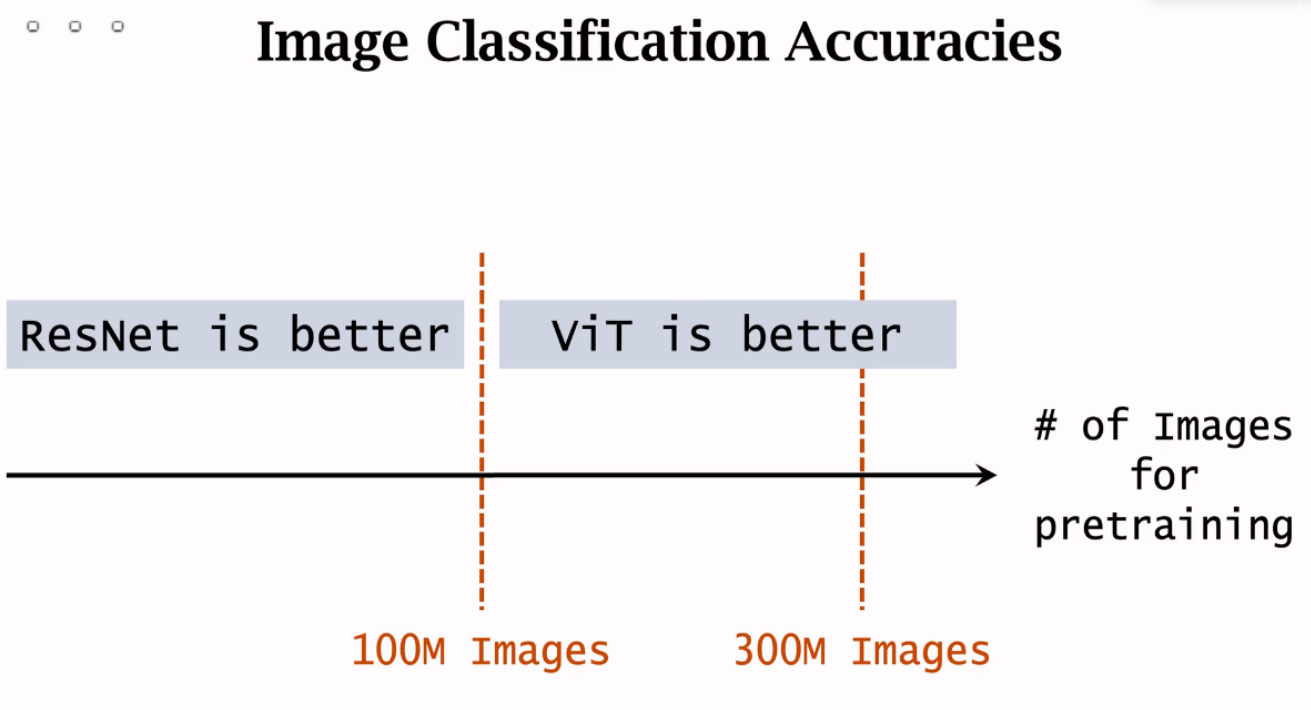

4.模型的缺点与改进

01 背景知识

02 模型介绍

03 模型训练策略

04 模型的缺点与改进

05 模型的代码实现

4.模型缺点与改进

ViT缺点

Vision Transformer比CNN具有更少的图像特异性归纳偏差。

在CNN中，局部性、二维邻域结构和平移等方差被融入到整个模型的每一层中。

在ViT中，只有MLP层是局部的、平移等变的，而自注意层是全局的。

二维邻域结构的使用非常少：在模型的开始通过将图像分割成小块，在微调时调整不同分辨率图像的位置嵌入。

除此之外，初始化时的位置嵌入不携带关于patch二维位置的信息，并且patch之间的所有空间关系都需要从头学习。

4.模型缺点与改进

改进

作为原始图像块的替代方法，输入序列可以由CNN的特征图形成。

在该混合模型中，将patch嵌入投影E应用于从CNN feature map中提取的patch。

作为一种特殊情况，patches的空间大小可以是1x1，这意味着输入序列是通过简单地打平feature map的空间维度并投射到Transformer维度来获得的。如前所述，增加分类输入嵌入和位置嵌入。

5.模型的代码实现

01 背景知识

02 模型介绍

03 模型训练策略

04 模型的缺点与改进

05 模型的代码实现

5. 模型的代码实现

主要思路

- 一个图片224x224，分成了49个32x32的patch；
- 对这么多的patch做embedding，成49个128向量；
- 再拼接一个cls_tokens，变成50个128向量；
- 再加上pos_embedding，还是50个128向量；
- 这些向量输入到transformer中进行自注意力的特征提取；
- 输出的是50个128向量，然后对这个50个求均值，变成一个128向量；
- 然后线性层把128维变成2维从而完成二分类任务的transformer模型。

5. 模型的代码实现

代码实现见代码文件

参考文献

1. https://jalammar.github.io/illustrated-transformer
2. https://www.bilibili.com/video/BV18Q4y1o7NY
3. Dosovitskiy. An image is worth 16×16 words: transformers for image recognition at scale. In ICLR.
4. 唐宇迪， https://www.bilibili.com/
5. https://www.bilibili.com/video/BV1Uu411o7oY


谢 谢!